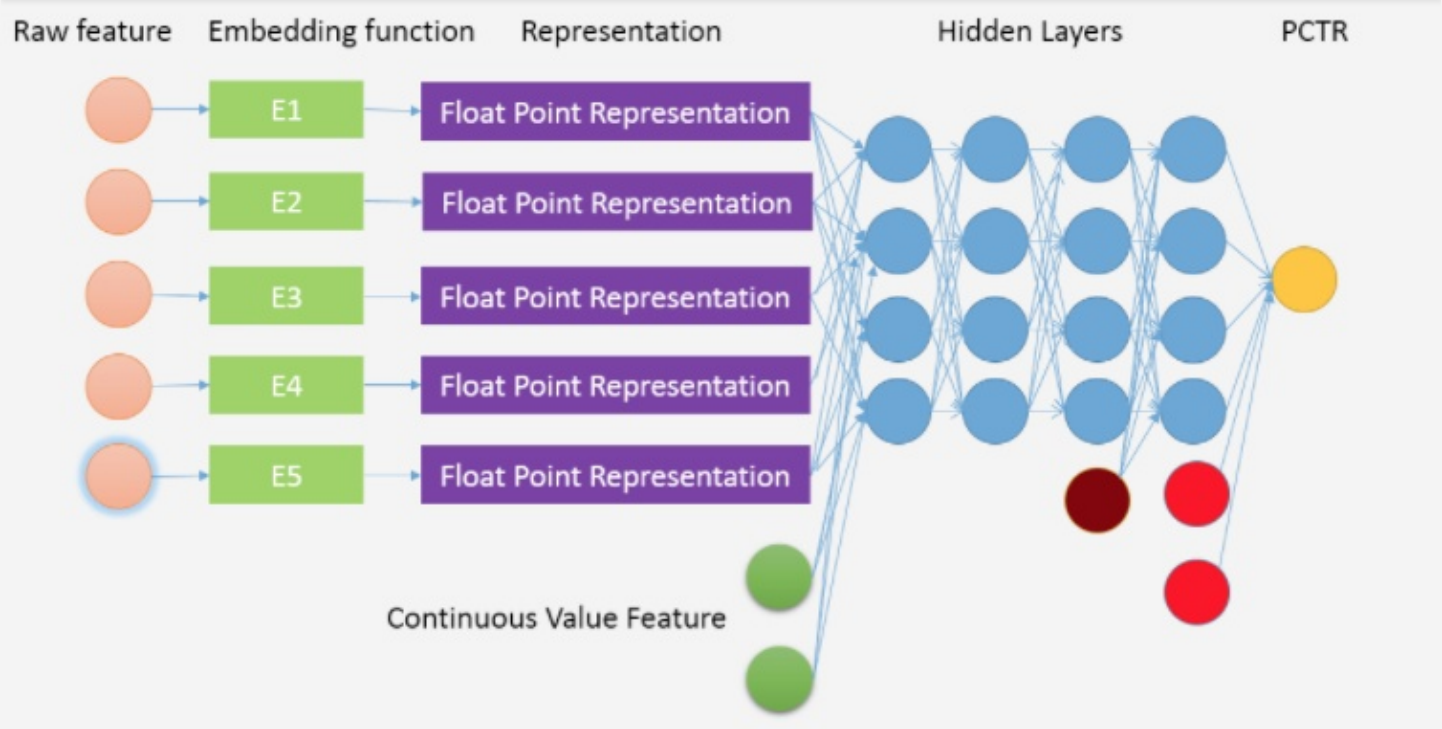

深度学习在CTR预估中的应用

辛俊波
广告ctr/推荐系统/机器学习/

一、前言

深度学习凭借其强大的表达能力和灵活的网络结构在NLP、图像、语音等众多领域取得了重大突破。在广告领域，预测用户点击率（Click Through Rate，简称CTR）领域近年也有大量关于深度学习方面的研究，仅这两年就出现了不少于二十多种方法，本文就近几年CTR预估领域中学术界的经典方法进行探究， 并比较各自之间模型设计的初衷和各自优缺点。通过十种不同CTR深度模型的比较，不同的模型本质上都可以由基础的底层组件组成。

本文中出现的变量定义：

- n: 特征个数，所有特征one-hot后 连接起来的整体规模大小
- f: 特征field个数，表示特征类别有多少个
- k: embedding层维度，在FM中是隐向量维度
- H1: 深度网络中第一个隐层节点个数，第二层H2，以此类推。

二、深度学习模型

FM模型可以看成是线性部分的LR，还有非线性的特征组合xixj交叉而成，表示如下：

$$y_{\mathrm{FM}}(\boldsymbol{x}) := \mathrm{sigmoid}\Big(w_0 + \sum_{i=1}^{N} w_i x_i + \sum_{i=1}^{N}\sum_{j=i+1}^{N} \langle \boldsymbol{v}_i, \boldsymbol{v}_j \rangle x_i x_j\Big)$$

Logistic Regression　　Feature Interactions

其中vi是第i维特征的隐向量，长度k<<n，包含k个描述特征的因子。参数个数为k*n。所有包含xi的非零组合特征都可以用来训练vi，缓解数据稀疏问题。图1是从神经网络的角度表示FM， 可以看成底层为特征维度为n的离散输入，经过embedding层后，对embedding层线性部分（LR）和非线性部分（特征交叉部分）累加后输出。

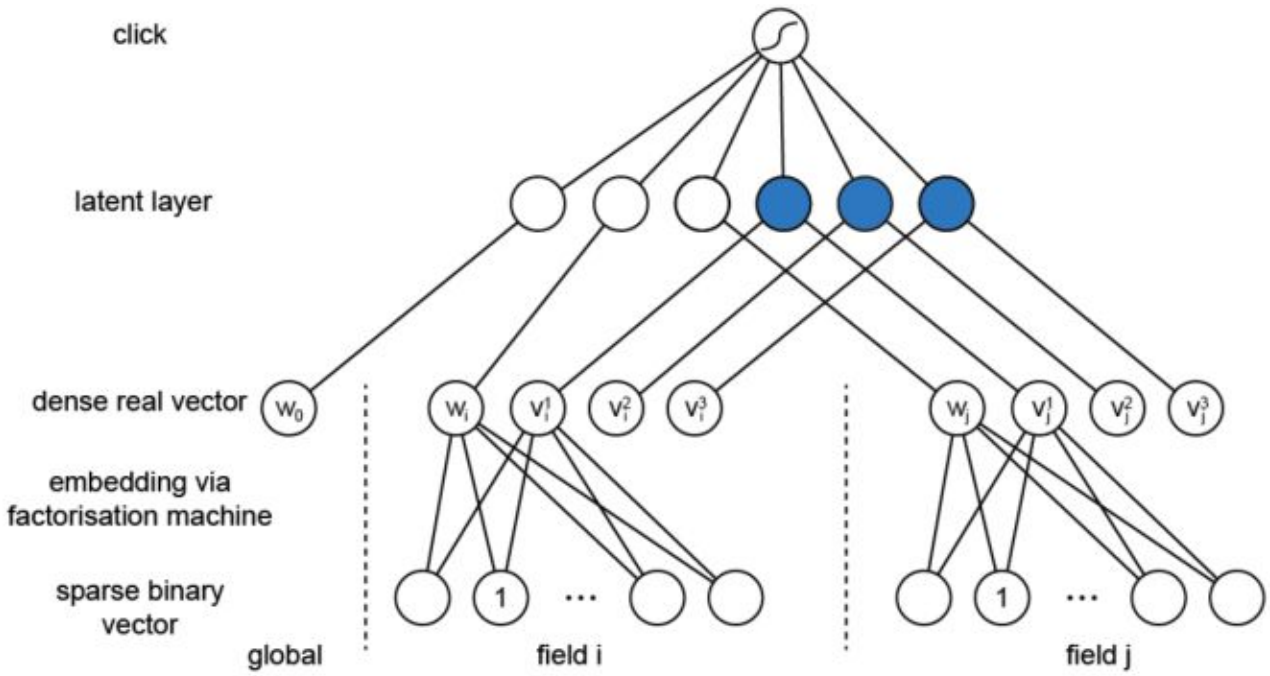

图1 FM模型结构

FM等价于FM + embedding，待学习的参数如下：

（1）LR部分： 1+n

（2）embedding 部分： n*k

FM下文中将作为各种网络模型的基础组件

2. Deep Neural Network(DNN)

类推。在第一层网络中，需要学习的参数就是n*H1。对于大多数CTR模型来说，特征体系都极其庞大而且稀疏，典型的特征数量级n从百万级到千万级到亿级甚至更高，这么大规模的n作为网络输入在ctr预估的工业界场景中是不可接受的。下面要讲到的大多数深度学习CTR网络结构，都围绕着如何将DNN的高维离散输入，通过embedding层变成低维稠密的输入工作来展开。

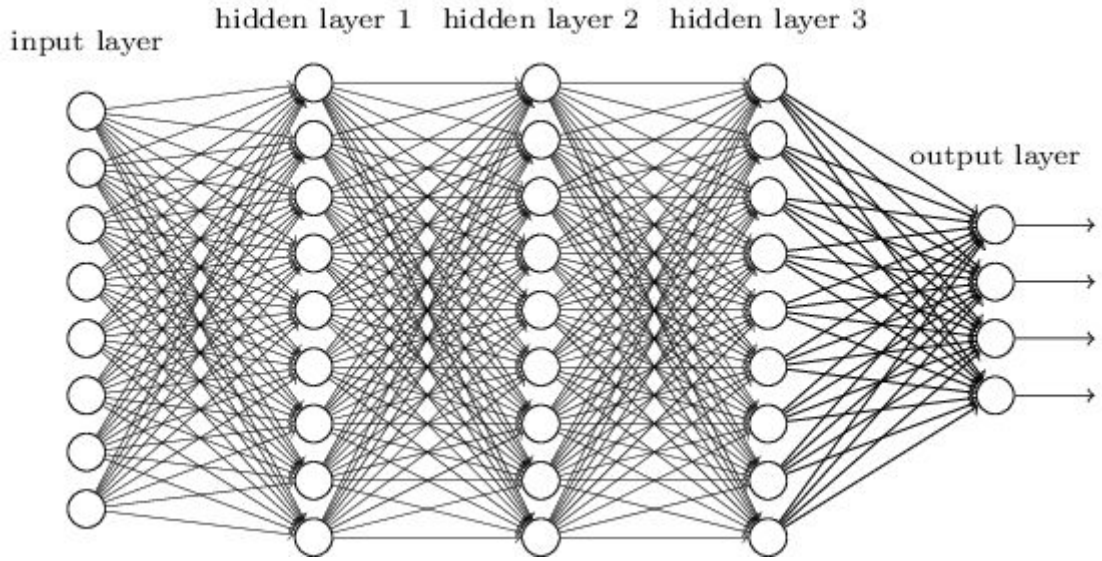

图2 DNN模型结构

DNN待学习参数： n*H1+H1*H2+H2*H3+H3*o(o为输出层大小，在ctr预估中为1)

DNN（后文称MLP）也将作为下文各种模型的基础组件之一

3. Factorization-machine supported Neural Networks (FNN)

在上述的DNN中，网络的原始输入是全部原始特征，维度为n，通常都是百万级以上。然而特征维度n虽然空间巨大，但如果归属到每个特征所属的field（维度为f），通常f维度会小很多。如果有办法将每个特征用其所属的field来表示，原始输入将大大减少不少。Factorisation-machine supported Neural Networks，简称FNN就是基于这种思想提出来的。

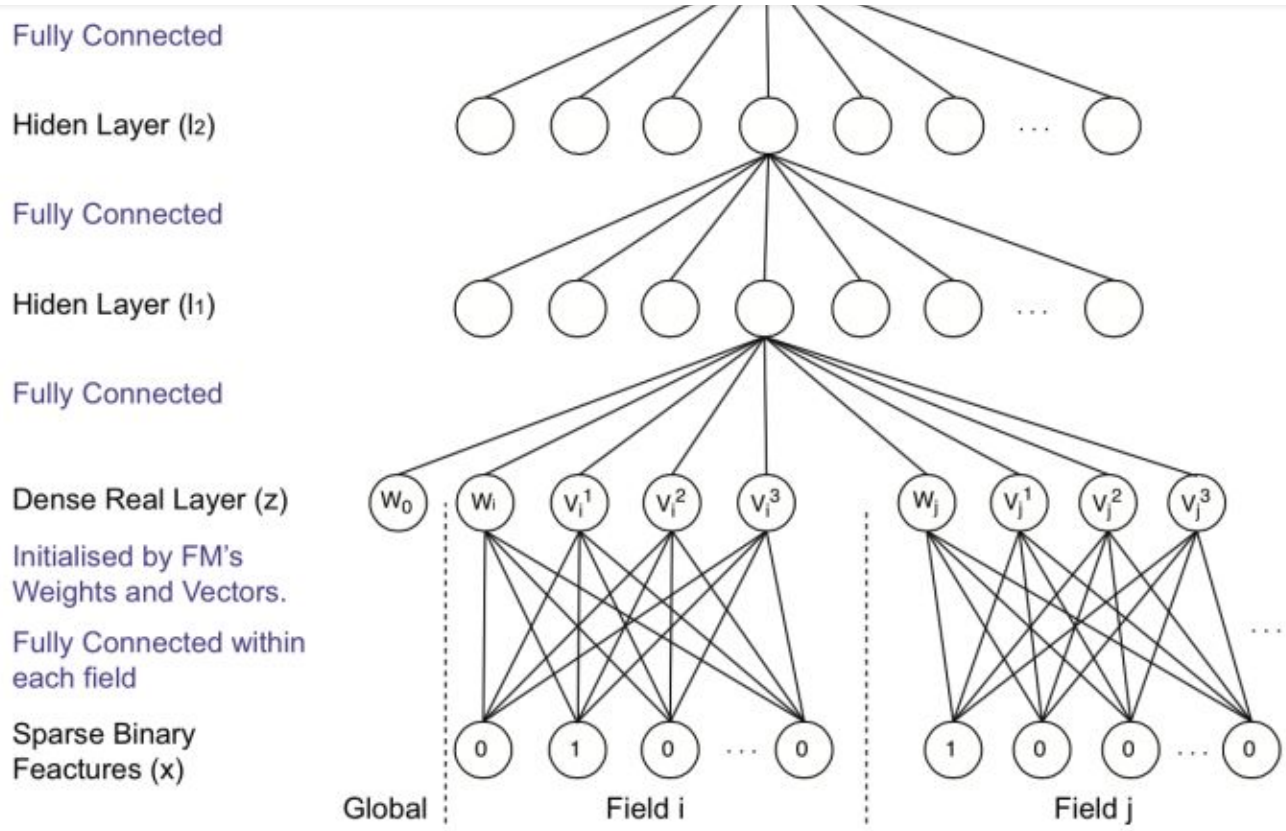

图3 FNN模型结构

FNN假设每个field有且只有一个值为1，其他均为0。x为原始输入的特征，它是大规模离散稀疏的。它可以分成n个field，每一个field中，只有一个值为1，其余都为0（即one hot）。 field i的输入可以表示成 x[start_i: end_i]， Wi为field i的embedding矩阵。 z为embedding后的向量，是一个k维的向量，它由一次项wi ，二次项vi=(vi1,vi2,...vik) 组成，其中k是FM中二次项的向量的维度。而后面的l1，l2则为神经网络的全连接层的表示。

除此之外，FNN还具有以下几个特点：

- **FM参数需要预训练**

FM部分的embedding需要预先进行训练，所以FNN不是一个end-to-end模型。在其他论文中，有试过不用FM初始化embedding, 而用随机初始化的方法，要么收敛速度很慢，要么无法收敛。有兴趣的同学可以实验验证下。

- **无法拟合低阶特征**

FM得到的embedding向量直接concat连接之后作为MLP的输入去学习高阶特征表达，最终的l输出作为ctr预估值。因此，FNN对低阶信息的表达比较有限。

- **每个field只有一个非零值的强假设**

本质上讲，FNN = LR+DEEP = LR + embedding + MLP，参数如下

（1）LR部分： 1+n

（2）embedding部分： n*k

（3）MLP部分： f*k*H1+H1*H2+H2

可以看到，对比DNN，在进入MLP部分之前，网络的输入由n降到了f*k（f为field个数，几十到几百之间，k为隐向量维度，一般0~100）

4. Product-based Neural Network(PNN)

FNN的embedding层直接concat连接后输出到MLP中去学习高阶特征。PNN，全称为Product-based Neural Network，认为在embedding输入到MLP之后学习的交叉特征表达并不充分，提出了一种product layer的思想，既基于乘法的运算来体现体征交叉的DNN网络结构，如图4所示。

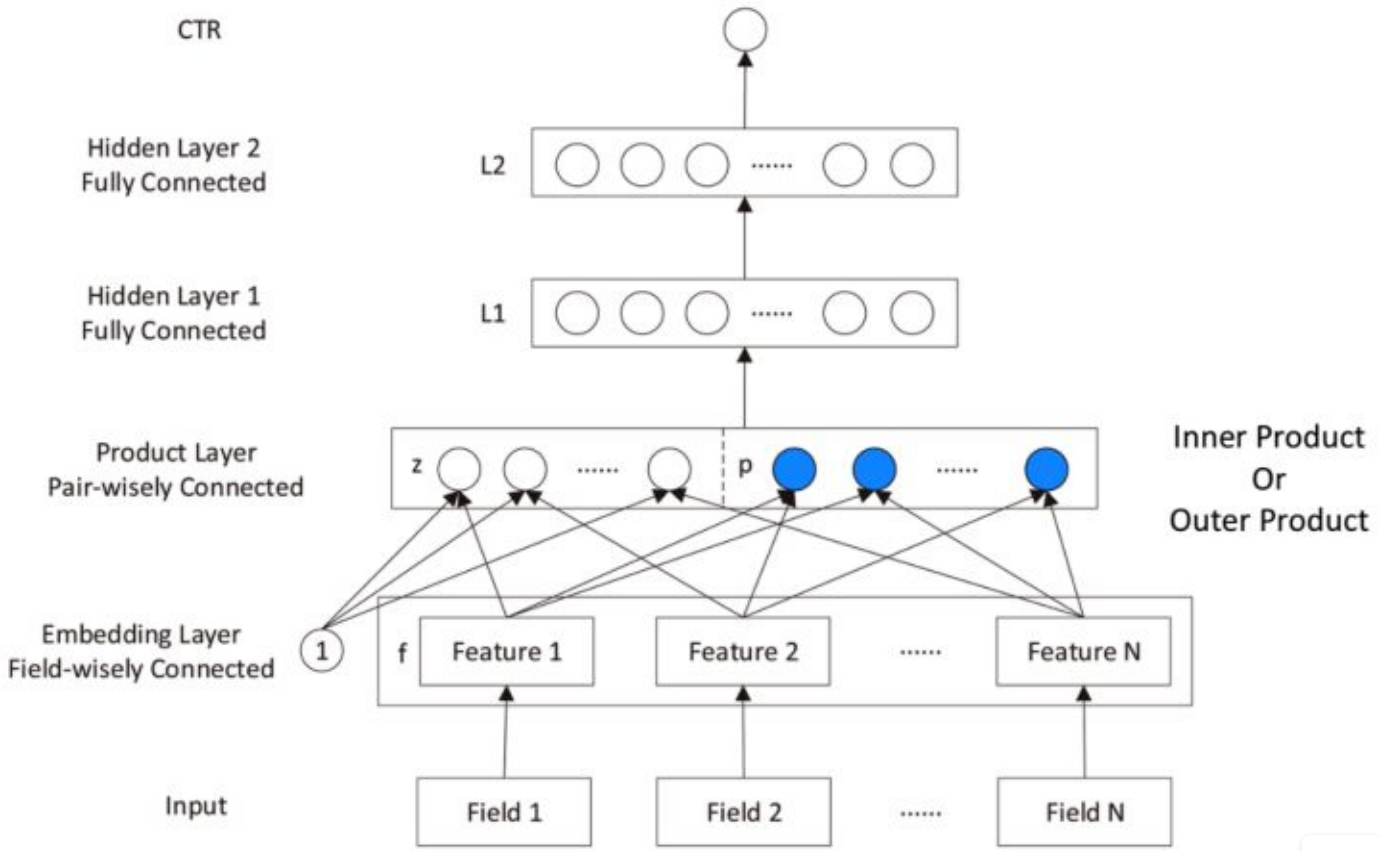

图4 PNN模型结构

同，PNN和FNN的MLP结构是一样的。这种product思想来源于，在ctr预估中，认为特征之间的关系更多是一种and“且”的关系，而非add"加”的关系。例如，性别为男且喜欢游戏的人群，比起性别男和喜欢游戏的人群，前者的组合比后者更能体现特征交叉的意义。根据product的方式不同，可以分为inner product（IPNN）和outer product(OPNN)，如图5所示。

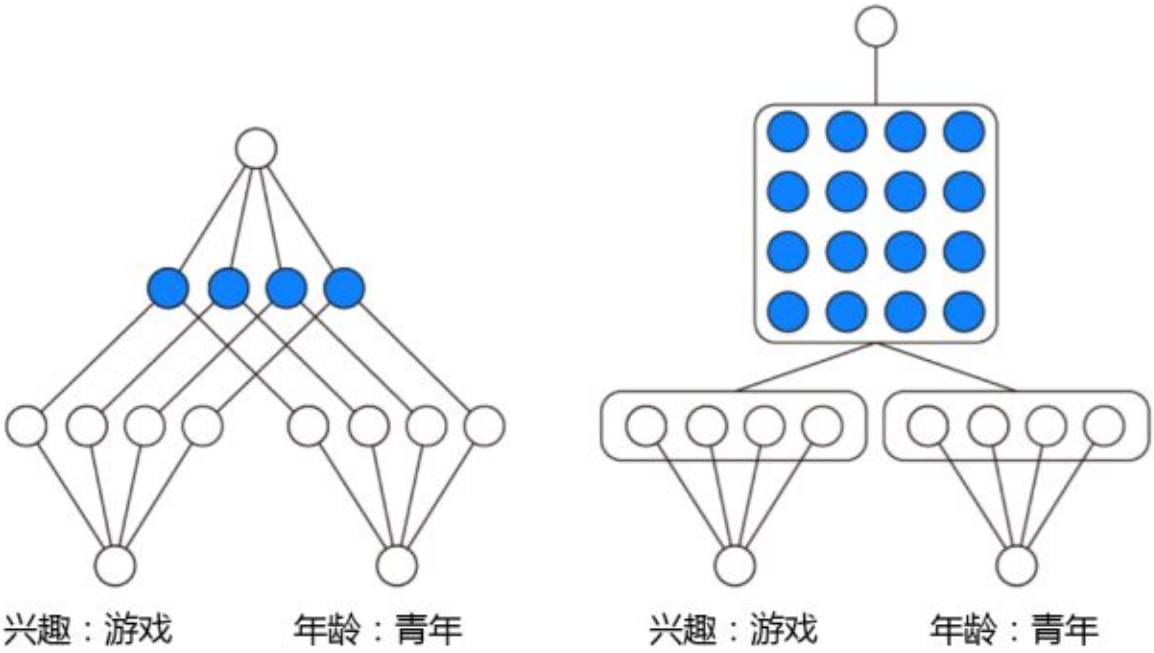

图5 PNN (左图：IPNN; 右图：OPNN)

Product layer的输出为

$$l_1 = relu(l_z + l_p + b_1)$$

- **Inner Product-based Neural Network**

IPNN的叉项使用了内积g(fi, fj) = <fi, fj>。f个filed，两两求内积共计交叉项p部分的参数共f*(f-1)/2(f为特征的field个数，原始论文里用的N）个，线性部分z部分参数共f*k个。需要学习的参数为：

（1）FM部分： 1+ n + n*k

（2）product部分： （f*k + f*(f-1)/2）*H1

（3）MLP部分：H1*H2+H2*1

- **Outer Product-based Neural Network**

（1）FM部分： 1+ n + n*k

（2）product部分： （f*k + f*(f-1)/2*k*k）*H1

（3）MLP部分：H1*H2+H2*1

5. Wide & Deep Learning (Wide&Deep)

前面介绍的两种变体DNN结构FNN和PNN，都在embedding层对输入做处理后输入MLP，让神经网络充分学习特征的高阶表达，deep部分是有了，对高阶的特征学习表达较强，但wide部分的表达是缺失的， 模型对于低阶特征的表达却比较有限。google在2016年提出了大名鼎鼎的wide&Deep的结构正是解决了这样的问题。Wide&deep结合了wide模型的优点和deep模型的优点，网络结构如图6所示，wide部分是LR模型，Deep部分是DNN模型。

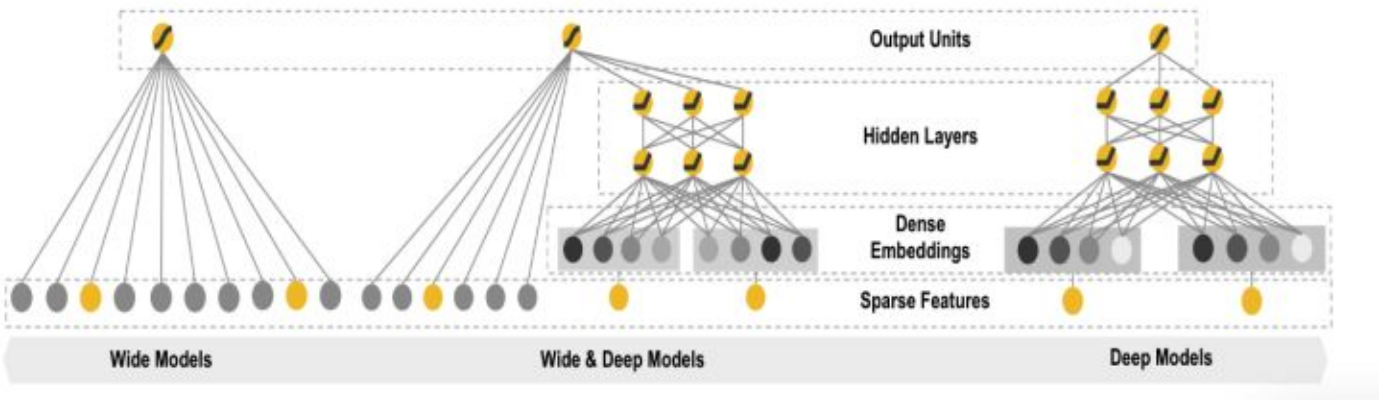

图6 Wide&Deep 模型结构

在这个经典的wide&deep模型中，google提出了两个概念，generalization（泛化性）和memory（记忆性）

- **Memory（记忆性）**

wide部分长处在于学习样本中的高频部分，优点是模型的记忆性好，对于样本中出现过的高频低阶特征能够用少量参数学习；缺点是模型的泛化能力差，例如对于没有见过的ID类特征，模型学习能力较差。

- **Generalization（泛化性）**

deep部分长处在于学习样本中的长尾部分，优点
出现过的样本都能做出预测（非零的embedding

除此之外，wide&deep模型还有如下特点

- **人工特征工程**

LR部分的特征，仍然需要人工设计才能保证一个不错的效果。因为LR部分是直接作为最终预测的一部分，如果作为wide部分的LR特征工程做的不够完善，将影响整个wide&deep的模型精度

- **联合训练**

模型是end-to-end结构，wide部分和deep部分是联合训练的

- **embedding层deep部分单独占有**

LR部分直接作为最后输出，因此embedding层是deep部分独有的。

wide&deep 等价于LR + embedding + MLP，需要学习的网络参数有：

1. LR: 1+n
2. embedding部分：n*k
3. MLP部分： f*k*H1 + H1*H2 + H2*1

6. Factorization-Machine based Neural Network (deepFM)

google提出的wide&deep框架固然强大，但由于wide部分是个LR模型，仍然需要人工特征工程。但wide&deep给整个学术界和工业界提供了一种框架思想。基于这种思想，华为诺亚方舟团队结合FM相比LR的特征交叉的功能，将wide&deep部分的LR部分替换成FM来避免人工特征工程，于是有了deepFM，网络结构如图7所示。

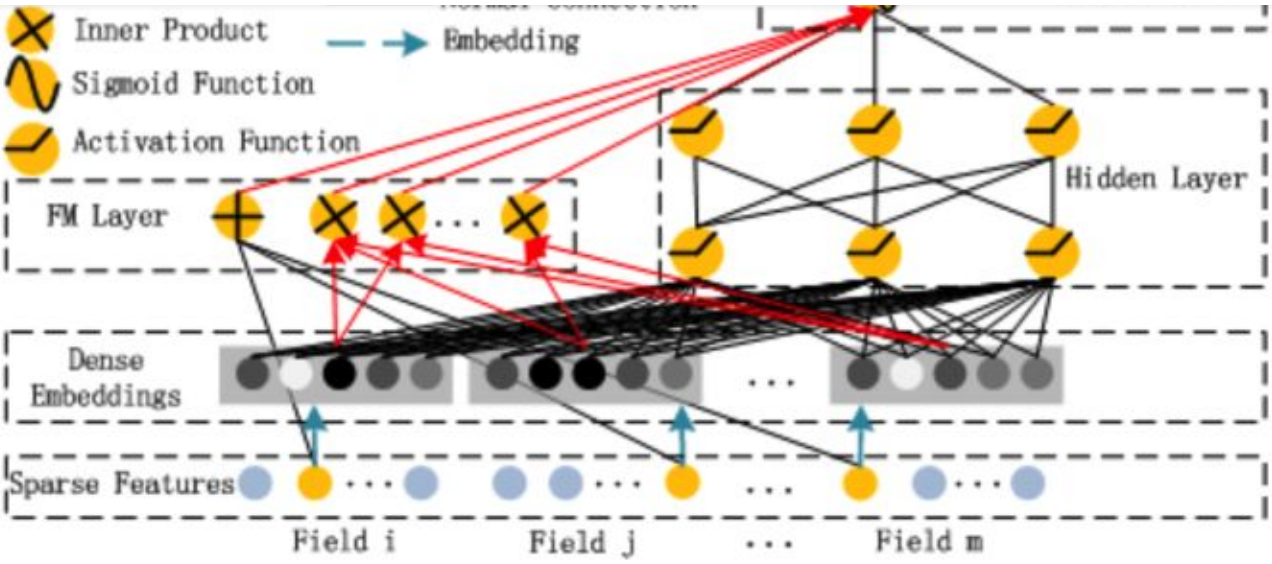

图7 DeepFM模型结构

比起wide&deep的LR部分，deeFM采用FM作为wide部分的输出，FM部分如图8所示。

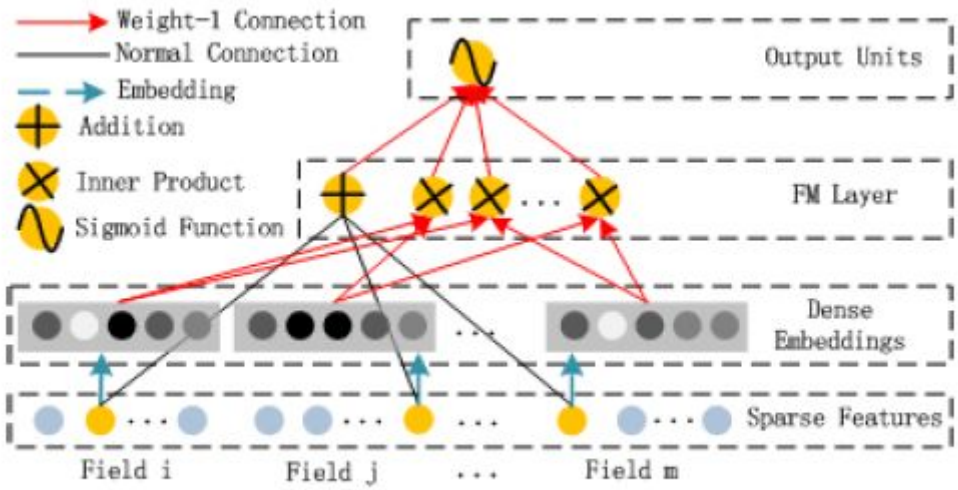

Figure 2: The architecture of FM.

$$y_{FM} = \langle w, x \rangle + \sum_{j_1=1}^{d} \sum_{j_2=j_1+1}^{d} \langle V_i, V_j \rangle x_{j_1} \cdot x_{j_2},$$

图8 deepFM模型中的FM部分结构

除此之外，deepFM还有如下特点：

- **低阶特征表达**

- **embedding层共享**

wide&deep部分的embedding层得需要针对deep部分单独设计；而在deepFM中，FM和DEEP部分共享embedding层，FM训练得到的参数既作为wide部分的输出，也作为DNN部分的输入。

- **end-end训练**

embedding和网络权重联合训练，无需预训练和单独训练

deepFM等价于FM + embedding + DNN

（1）FM部分： 1+n

（2）embedding部分：n*k

（3）DNN部分： f*k*H1 + H1*H2+H1

通过embedding层后，FM部分直接输出没有参数需要学习，进入DNN部分的参数维度从原始n维降到f*k维。

7. Neural Factorization Machines (NFM)

前面的deepFM在embedding层后把FM部分直接concat起来（f*k维，f个field，每个filed是k维向量）作为DNN的输入。Neural Factorization Machines，简称NFM，提出了一种更加简单粗暴的方法，在embedding层后，做了一个叫做BI-interaction的操作，让各个field做element-wise后sum起来去做特征交叉，MLP的输入规模直接压缩到k维，和特征的原始维度 n 和特征field 维度f没有任何关系。网络结构如图9所示。

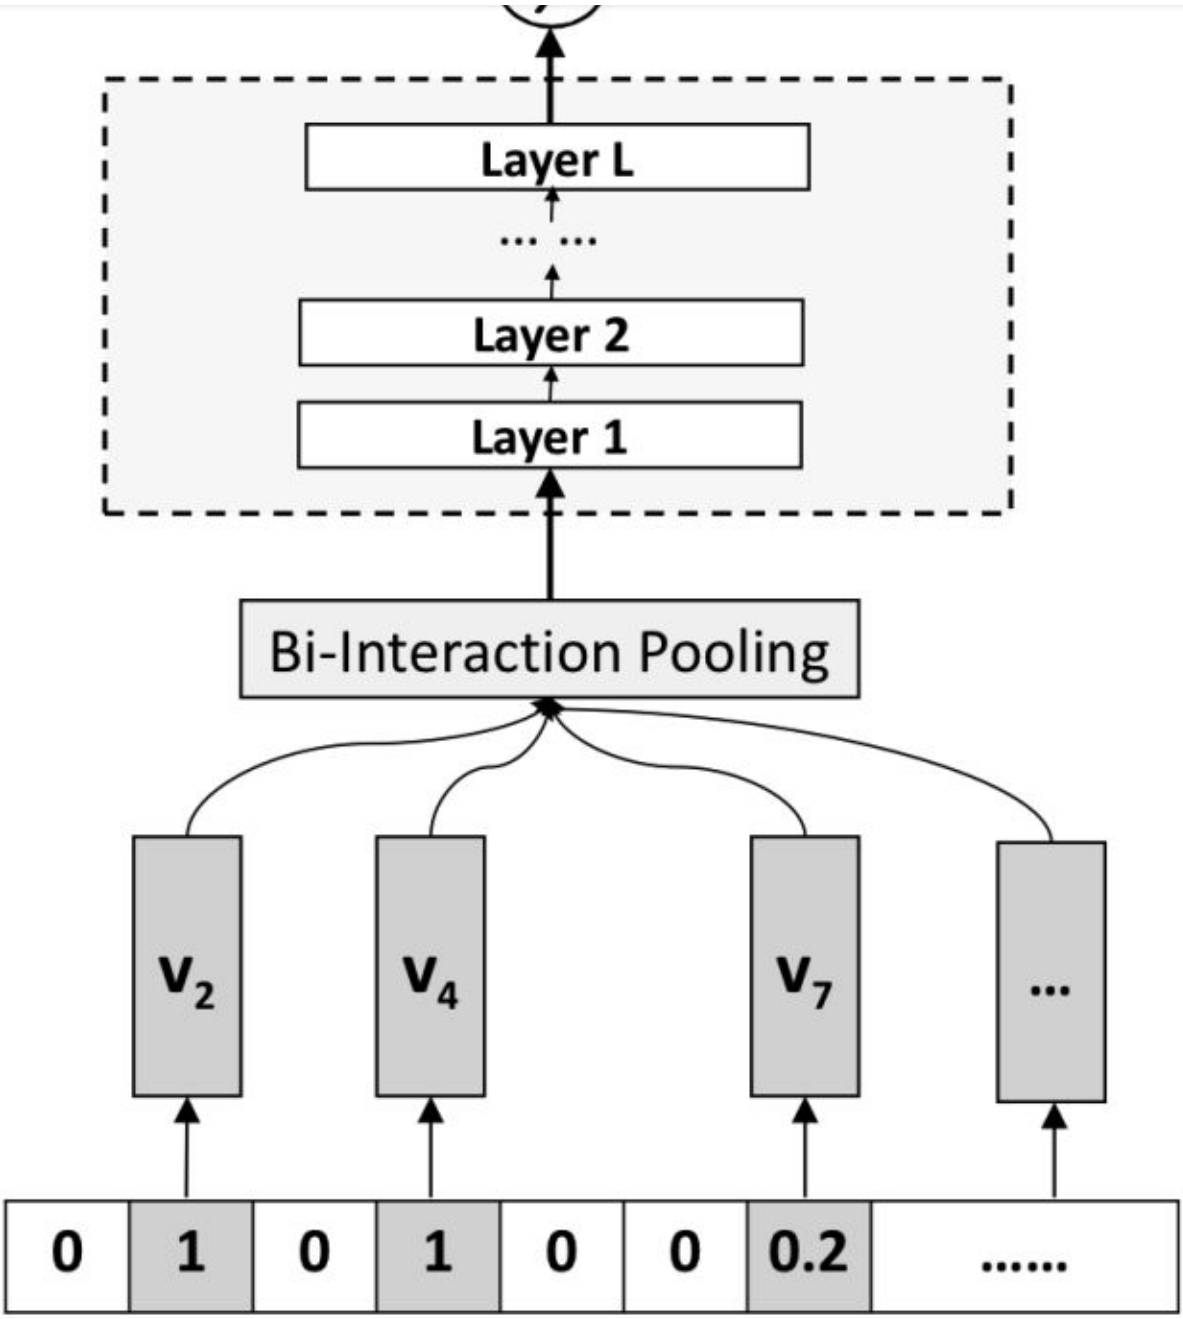

图9 NFM模型结构

这里论文只画出了其中的deep部分, wide部分在这里省略没有画出来。Bi-interaction听名字很高大上，其实操作很简单：就是让f个field两两element-wise相乘后，得到f*(f-1)/2个向量，然后直接sum起来，最后得到一个k维的向量。所以该层没有任何参数需要学习。

NFM等价于FM + embedding + MLP，需要学习的参数有：

（1）FM部分： 1+n

（2）embedding部分：n*k

NFM在embedding做了bi-interaction操作来做特征的交叉处理，优点是网络参数从n直接压缩到k（比FNN和deepFM的f*k还少），降低了网络复杂度，能够加速网络的训练得到模型；但同时这种方法也可能带来较大的信息损失。

8. Attention Neural Factorization Machines (AFM)

前面提到的各种网络结构中的FM在做特征交叉时，让不同特征的向量直接做交叉，基于的假设是各个特征交叉对ctr结果预估的贡献度是一样的。这种假设其实是不合理的， 不同特征在做交叉时，对ctr预估结果的贡献度是不一样的。Attention Neural Factorization Machines，简称NFM模型，利用了近年来在图像、NLP、语音等领域大获成功的attention机制，在前面讲到的NFM基础上，引入了attention机制来解决这个问题。AFM的网络结构如图10所示。和NFM一样，这里也省略了wide部分，只画出了deep部分结构。

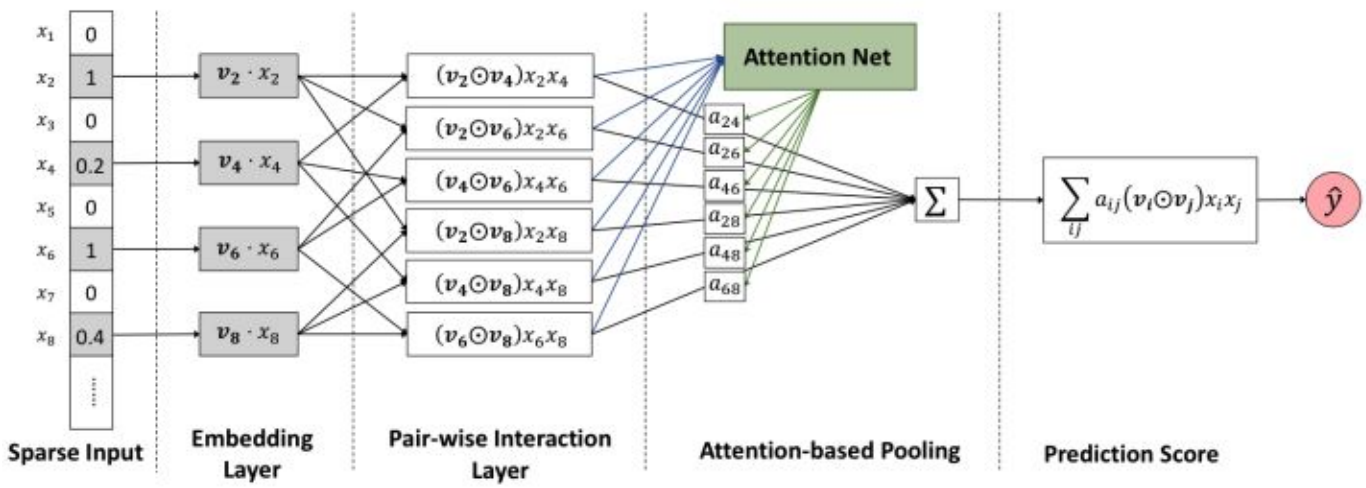

图10 AFM模型结构

AFM的embedding层后和NFM一样，先让f个field的特征做了element-wise product后，得到f*(f-1)/2个交叉项。和NFM直接把这些交叉项sum起来不同，AFM引入了一个Attention Net，认为这些交叉特征项每个对结果的贡献是不同的，例如xi和xj的权重重要度，用aij来表示。从这个角度来看，其实AFM其实就是个加权累加的过程。Attention Net部分的权重aij不是直接学习，而是通过如下公式表示

$$a_{ij} = \frac{\exp(a'_{ij})}{\sum_{(i,j)\in\mathcal{R}_x} \exp(a'_{ij})},$$

$$\mathbf{W} \in \mathbb{R}^{t\times k}, \mathbf{b} \in \mathbb{R}^t, \mathbf{h} \in \mathbb{R}^t$$

这里t表示attention net中的隐层维度，k和前面一样，为embedding层的维度。所以这里需要学习的参数有3个，W, b, h，参数个数共t*k+2*t个。得到aij权重后，对各个特征两两点积加权累加后，得到一个k维的向量，引入一个简单的参数向量pT，维度为k进行学习，和wide部分一起得到最终的AFM输出。

$$y'_{AFM} = w_0 + \sum_{i=1}^{n} w_i x_i + p^T \sum_{i=1}^{n} \sum_{j=i+1}^{n} a_{ij}(v_i \odot v_j) x_i x_j$$

wide部分　　Attention部分

总结AFM的网络结构来说，有如下特点：

- **Attention Network**

AFM的亮点所在，通过一个attention net生成一个关于特征交叉项的权重，然后将FM原来的二次项直接累加，变成加权累加。本质上是一个**加权平均**，学习xjxj的交叉特征重要性

- **Deep Network**

没有deep，卒。

Attention net学习得到的交叉项直接学些个pt参数就输出了，少了DNN部分的表达，对高阶特征部分的进一步学习可能存在瓶颈。另外，FFM其实也引入了field的概念去学习filed和featrue之间的权重。没有了deep 部分的AFM，和优化的FFM上限应该比较接近。

AFM等价于 FM + embedding + attention + MLP(一层)　需要学习的参数有：

（2）Embedding部分参数: n*k

（3）Attention Network部分参数： k*t + t*2

（4）MLP部分参数：k*1

9. Deep&Cross Network(DCN)

在ctr预估中，特征交叉是很重要的一步，但目前的网络结构，最多都只学到二级交叉。LR模型采用原始人工交叉特征，FM自动学习xi和xj的二阶交叉特征，而PNN用product方式做二阶交叉，NFM和AFM也都采用了Bi-interaction的方式学习特征的二阶交叉。对于更高阶的特征交叉，只有让deep去学习了。为解决这个问题，google在2017年提出了Deep&Cross Network，简称DCN的模型，可以任意组合特征，而且不增加网络参数。图11为DCN的结构。

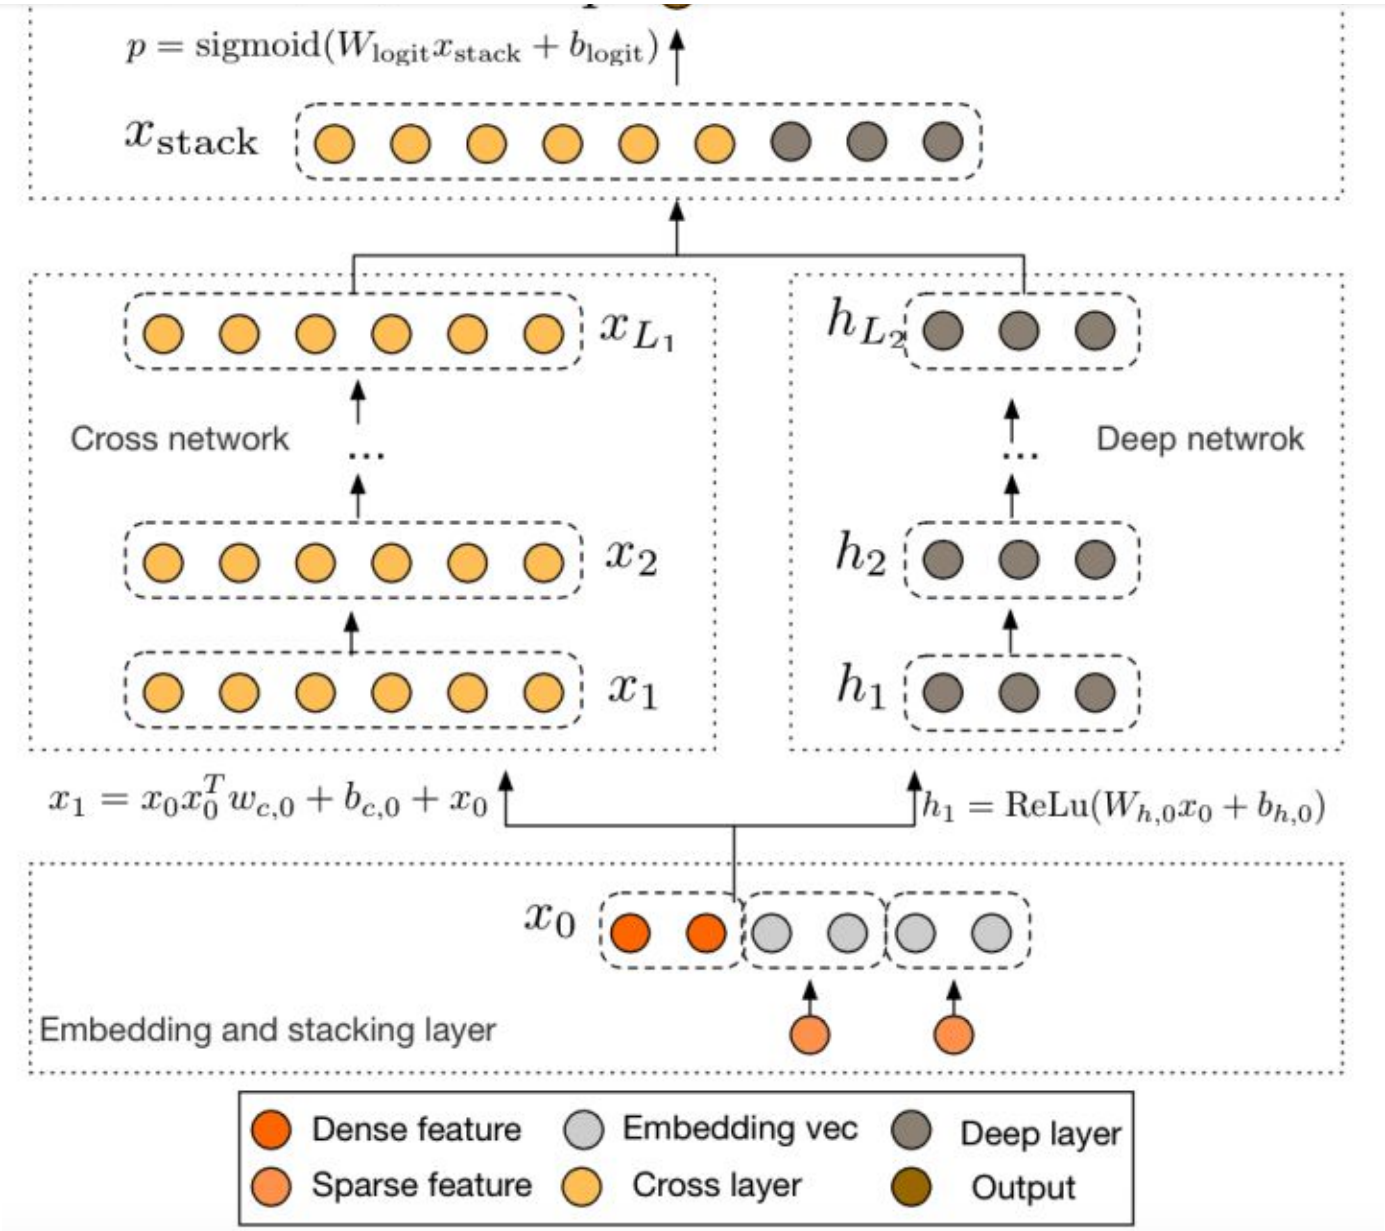

图11 DCN模型结构

整个网络分4部分组成：

（1）Embedding and stacking layer

之所以不把embedding和stacking分开来看，是因为很多时候，embedding和stacking过程是分不开的。前面讲到的各种 XX-based FM 网络结构，利用FM学到的v向量可以很好的作为embedding。而在很多实际的业务结构，可能已经有了提取到的embedding特征信息，例如图像的特征embedding，text的特征embedding，item的embedding等，还有其他连续值信息，例如年龄，收入水平等，这些embedding向量stack在一起后，一起作为后续网络结构的输入。当然，这部分也可以用前面讲到的FM来做embedding。为了和原始论文保持一致，这里我们假设X0向量维度为d（上文的网络结构中为k），这一层的做法就是简单的把多种

$$\mathbf{x}_0 = [\mathbf{x}_{\text{embed},1}, \cdots, \mathbf{x}_{\text{embed},k}, \mathbf{x}_{\text{dense}}],$$

（2）Deep layer netwok

在embedding and stacking layer之后，网络分成了两路，一路是传统的DNN结构。表示如下

$$\mathbf{h}_{l+1} = f(W_l \mathbf{h}_l + \mathbf{b}_l),$$

为简化理解，假设每一层网络的参数有m个，一共有Ld层，输入层由于和上一层连接，有d*m个参数（d为x0向量维度），后续的Ld-1层，每层需要m*(m+1)个参数，所以一共需要学习的参数有d*m+m*(m+1)*(Ld-1)。最后的输出也是个m维向量Hl2

（3）Cross layer network

Embedding and stacking layer输入后的另一路就是DCN的重点工作了。假设网络有L1层，每一层和前一层的关系可以用如下关系表示

$$\mathbf{x}_{l+1} = \mathbf{x}_0 \mathbf{x}_l^T \mathbf{w}_l + \mathbf{b}_l + \mathbf{x}_l = f(\mathbf{x}_l, \mathbf{w}_l, \mathbf{b}_l) + \mathbf{x}_l,$$

可以看到f是待拟合的函数，xl即为上一层的网络输入。需要学习的参数为wl和bl，因为xl维度为d， 当前层网络输入xl+1也为d维，待学习的参数wl和bl也都是d维度向量。因此，每一层都有2*d的参数（w和b）需要学习，网络结构如下。

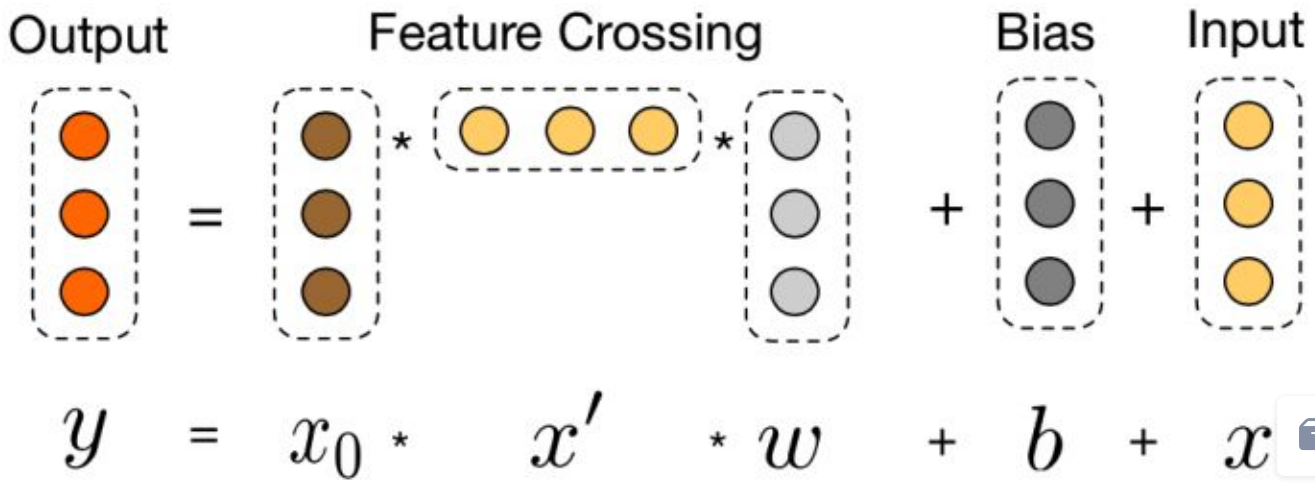

（4）Combination Output Layer

经过cross network的输出XL1(d维）和deep network之后的向量输入（m维）直接做concat，变为一个d+m的向量，最后套一个LR模型，需要学习参数为1+d+m。

总结起来，DCN引入的cross network理论上可以表达任意高阶组合，同时每一层保留低阶组合，参数的向量化也控制了模型的复杂度。

DCN等价于embedding + cross + deep + LR

（1）embedding部分参数: 根据情况而定

（2）cross部分参数：2*d*Lc(Lc为cross网路层数）

（3）deep部分参数：d*(m+1)+m*(m+1)*(Ld-1) (Ld为深度网络层数，m为每层网络参数）

（4）LR 部分参数：1+d+m

10. Deep Interest Network (DIN)

最后介绍阿里在2017年提出的Deep Interest Network，简称DIN模型。与上面的FNN,PNN等引入低阶代数范式不同，DIN的核心是基于数据的内在特点，引入了更高阶的学习范式。用户的兴趣是多种多样的，从数学的角度来看，用户的兴趣在兴趣空间是一个多峰分布。在预测ctr时，用户embedding表示的兴趣维度，很多是和当前item是否点击无关的，只和用户兴趣中的局部信息有关。因此，受attention机制启发，DIN在embedding层后做了一个action unit的操作，对用户的兴趣分布进行学习后再输入到DNN中去，网络结构如图12所示

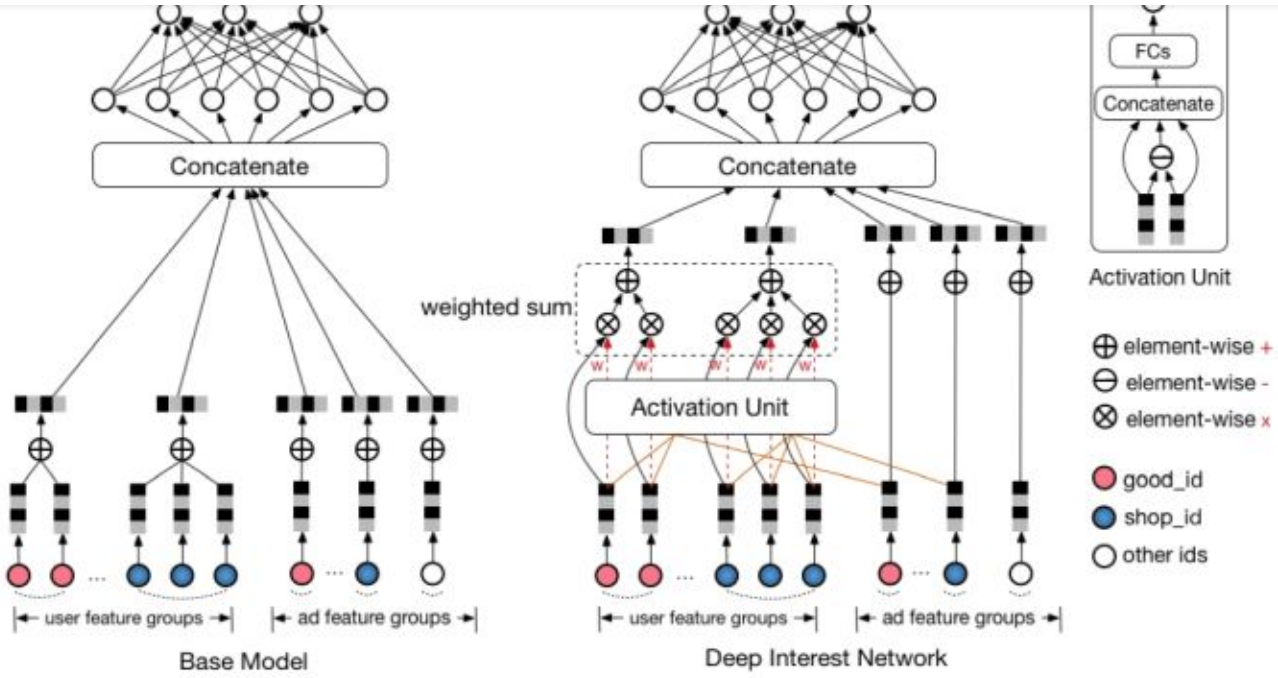

图12 DIN模型结构

DIN把用户特征、用户历史行为特征进行embedding操作，视为对用户兴趣的表示，之后通过attention network，对每个兴趣表示赋予不同的权值。

- Vu：表示用户最终向量
- Vi：表示用户兴趣向量(shop_id, good_id..)
- Va：表示广告表示向量
- Wi: 对于候选广告，attention机制中该兴趣的权重

$$V_u = f(V_a) = \sum_{i=1}^{N} w_i * V_i = \sum_{i=1}^{N} g(V_i, V_a) * V_i$$

可以看到，对于用户的每个兴趣向量Vi，都会通过学习该兴趣的权重Vi, 来作为最终的用户表示。

三、写在最后

前面介绍了10中深度学习模型的网络结构，总结起来可以用如下的所表示

LR	是	LR	1+n	否	是	否
FM	否	FM	1+n+n*k	否	是	是
DNN	否	MLP	n*H1 + H1*H2 + H2*1	否	否	是
FNN	否	FM + MLP	1+n+n*k+(1+f+f*k)*H1+H1*H2+H2*1	是	否	是
PNN	否	FM + product + MLP	IPNN: 1 +n + n*k +(f*k + f*(f-1)/2)*H1+H1*H2 + H2*1 OPNN: 1 + n + n*k +(f*k + f*(f-1)/2*k*k)*H1 + H1*H2 + H2*1	否	否	是
wide &deep	是	LR + embedding + MLP	1+n+n*k + f*k*H1+H1*H2+H2	否	是	是
deepFM	否	FM + embedding + MLP	1+n+n*k + f*k*H1 + H1*H2 + H1	否	是	是
NFM	否	FM + embedding + MLP	1+ n + n*k + k*H1 + H1*H2 + H2*1	否	是	是
AFM	否	FM +embedding +attention + MLP	1+n+n*k + k*H1+H1*2+k*1	否	是	是
DCN	否	embedding + cross + MLP +LR	1+n+2*d*Lc +d*(m+1)+m*(m+1)*(Ld-1) + 1 + d + m	否	是	是
DIN	否	embedding + attention + MLP	n*k + attention + f*k*H1 + H1*H2+H2*1	否	是	是

各种CTR深度模型看似结构各异，其实大多数可以用如下的通用范式来表达，

- **input->embedding:**

把大规模的稀疏特征ID用embedding操作映射为低维稠密的embedding向量

- **embedding层向量**

concat, sum, average pooling等操作，大部分CTR模型在该层做改造

- **embedding->output:**

通用的DNN全连接框架，输入规模从n维降为k*f维度甚至更低。

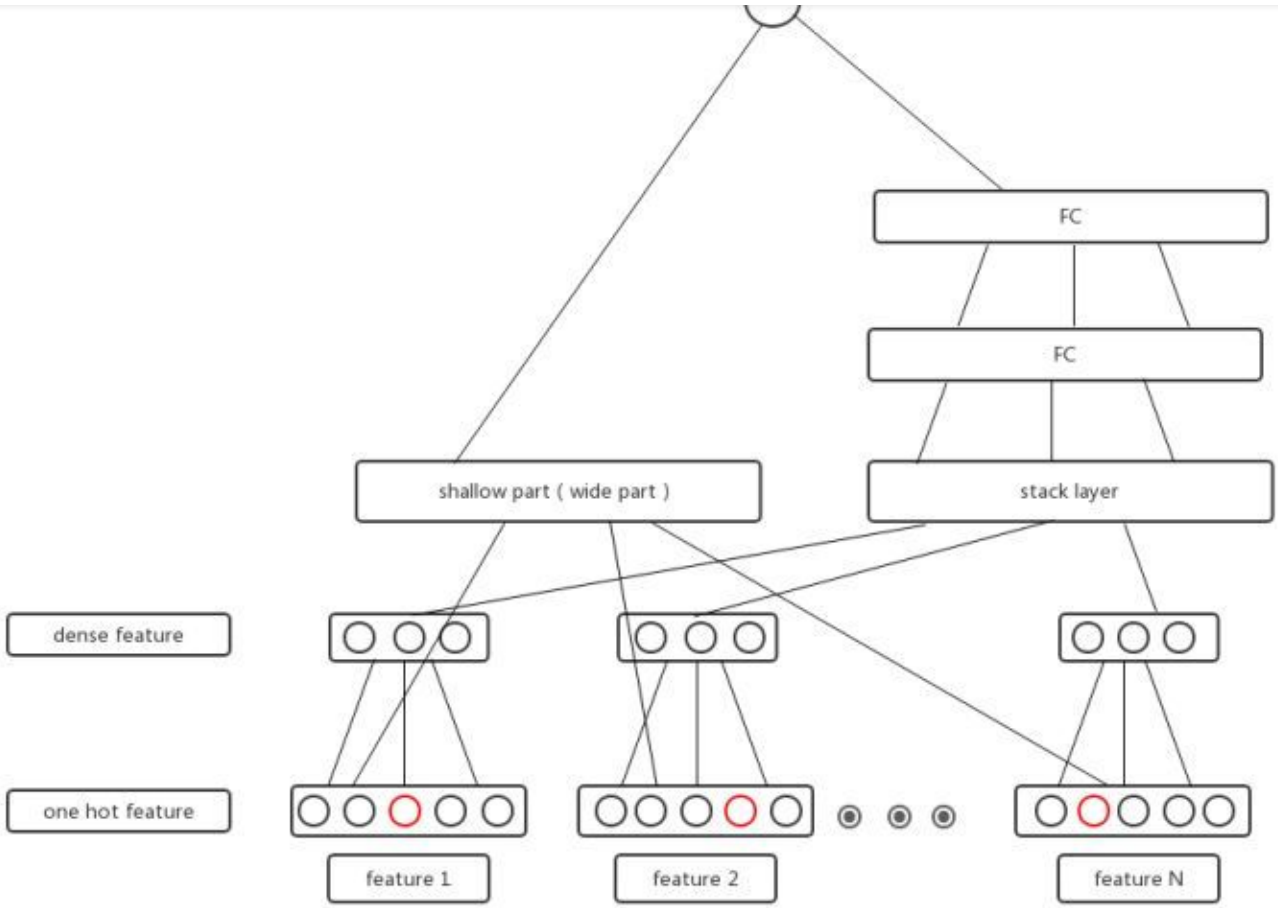

图13 通用深度学习模型结构

其中，embedding vector这层的融合是深度学习模型改造最多的地方，该层是进入深度学习模型的输入层，embedding 融合的质量将影响DNN模型学习的好坏。个人总结大体有以下4种操作，当然后续可能会有越来越多其他的变形结构。

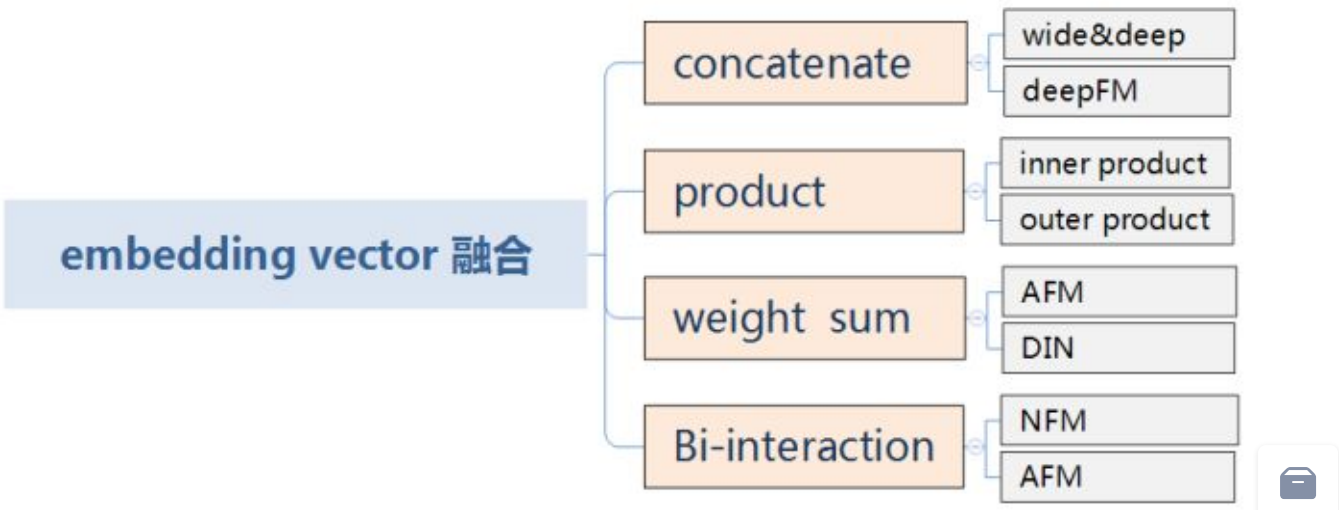

图14 embedding层融合方式

等。

写在最后

ctr预估领域不像图像、语音等领域具有连续、稠密的数据以及空间、时间等的良好局部相关性，ctr预估中的大多数输入都是离散而且高维的，特征也分散在少量不同的field上。要解决这样的一个深度学习模型，面临的第一个问题是怎么把输入向量用一个embedding层降维策划那个稠密连续的向量，如本文介绍的用FM去做预训练，或者和模型一起联合训练，或者其他数据源提取的embedding特征向量去做concat。其次，在宽和深的大战中，在google在提出了wide&deep的模型框架后，这套体系基本已成为业内的基本框架。无论wide部分或者deep怎么改造，其实本质上还是一些常见组件的结合，或者改造wide，或者改造deep，或者在wide和deep的结合过程中进行改造。

ctr预估领域方法变化层出不穷，但万变不离其宗，各种模型本质上还是基础组件的组合，如何结合自己的业务、数据、应用场景去挑选合适的模型应用，可能才是真正的难点所在。

四、参考文献

[1]Factorization Machines

[2]Wide & Deep Learning for Recommender Systems

[3]Deep Learning over Multi-Field Categorical Data: A Case Study on User Response Prediction

[4]Product-based Neural Networks for User Response Prediction

[5]DeepFM: A Factorization-Machine based Neural Network for CTR Prediction

[6]Neural Factorization Machines for Sparse Predictive Analytics

[7] Attentional Factorization Machines: Learning the Weight of Feature Interactions via Attention Networks

[8]Deep & Cross Network for Ad Click Predictions

[9]Deep Interest Network for Click-Through Rate Prediction

发布于 2018-04-10

知乎 首发于 闲聊广告ctr预估模型

文章被以下专栏收录

闲聊广告ctr预估模型 关注专栏

推荐阅读

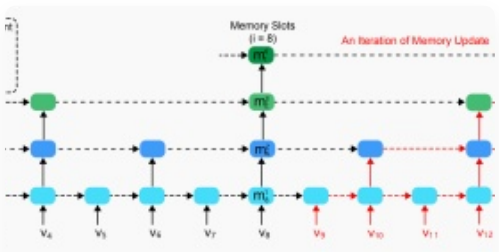

阿里巴巴&上海交大基于用户终生行为建模的CTR预估模型—...

被包养的程... 发表于独立团丶

镶嵌在互联网技术上的明珠：漫谈深度学习时代点击率预估技...

朱小强 发表于高维稀疏数...

26 条评论

切换为时间排序

写下你的评论...

精选评论（1）

辛俊波 (作者) 回复 会旋转的霸东 1 年前

这些文章的重点集中在DNN模型结构的改进工作上，ctr预估的其他问题，如样本选择，特征工程，线上线下评估等工作照样还是需要的，那些都不是这些文章的重点了。至于你说到的本不平衡问题，在ctr预估中其实并不是太主要的问题，训练样本分布如果和线上数据分布一致的话，没必要进行样本均衡。在业务中，
考虑。例如线上1%不到的ctr, 1:100左右的正

▲ 赞同 290 ▼ 26 条评论 分享

在ctr预估业务实践中关于样本选择问题的文章

6 查看回复

评论（26）

λ lambdaJi 1 年前

wnzhang在GitHub上提过FNN没有预训练也能收敛，criteo上收敛曲线跟IPNN差不多

赞

辛俊波 (作者) 回复 lambdaJi 1 年前

没有做过该实验，和同事讨论说随机初始化的FNN在业务数据集上也能收敛，但收敛速度慢很多

赞

Andy Jee 1 年前

给师兄点赞

赞

飞奔的啦啦啦 1 年前

想问一下 特征中的连续值一般如何处理

赞

辛俊波 (作者) 回复 飞奔的啦啦啦 1 年前

如果是LR模型，根据业务知识做离散化；如果是DNN模型，做了归一化后，可以直接在input层或者其他任意DNN隐层（尤其是最后的softmax层，参考wide&deep）和其他embedding层concat后丢进去模型。参考封面图中最后两层下方的绿色圆圈和红色圆圈，连续值可以尝试在不同的网络层和该层其他input concat后作为该层的input

赞

会旋转的霸东 1 年前

这些算法为啥都没怎么处理不平衡呢？在做业务的时候也不处理吗？

赞

过忘 回复 会旋转的霸东 1 年前

同问！

赞

辛俊波 (作者) 回复 会旋转的霸东

你说到的样本不平衡问题，在ctr预估中其实并不是太主要的问题，训练样本分布如果和线上数据分布一致的话，没必要进行样本均衡。在业务中，用LR的时候对负样本进行负采样更多是处于性能考虑。例如线上1%不到的ctr, 1:100左右的正负样本比例，珍贵的是正样本，加入更多信息量少的负样本对模型效果提升并不大，所以可以做负采样，既提升性能，也不影响效果。当然最后也需要进行截距修正。DNN中为了不改变样本分布，我们是直接丢进去训练的。后续会写在ctr预估业务实践中关于样本选择问题的文章

6

展开其他 3 条回复

修聪 1 年前

谢谢楼主的分享，最近正打算在我司implement一个deepFM试试看效果，但是目前对于inference speed有点担忧，怕不能满足real time bidding的要求，不知道楼主在这方面有没有什么经验?

赞

辛俊波 (作者) 回复 **修聪** 1 年前

线上predict我们在tf serving 上封装了业务，主要的耗时还是在特征拼接上，整体耗时稳定性比lr要差些，工程侧还在优化。可以先折腾一个版本上线看看，在线上效率收益提升较大情况下不断去做工程优化吧

赞

庄宝童 回复 **辛俊波** (作者) 1 年前

实时inference，还是用的 CPU吧？能否透露 QPS，latency 大概情况?

赞

展开其他 1 条回复

王晓伟 1 年前

AFM，这样加attention有什么作用？也没有引入其他信息，就是自己跟自己做attention，感觉和多加几个隐藏层的效果一样啊

赞

辛俊波 (作者) 回复 **王晓伟** 1 年前

我理解是特征交叉xixj对最终输出表达更强了吧，deep部分也省略了，乘以aij后直接就作为输出了，想强调对特征交叉输入到deep去学习还不如学习得到各自attention好用。至于效果还得看数据集吧

赞

王晓伟 回复 **辛俊波** (作者)

赞

吕欣蔚 1 年前

请教您一下，连续变量使用FM是需要进行分箱操作的是吗

赞

Robert年 1 年前

您好，embedding： n*k，这个怎么理解？ 这样参数不是和直接全连接一样吗？是不是（n1*k1 + n2*k2+。。。）

赞

我是CCB 1 年前

很系统很详细~好像微软还有一篇kdd16的deep crossing~AFM实践感觉有点鸡肋啊，速度慢，效果也不好~

1

Ning Lee 1 年前

这才是原作吗？真的佩服，写的太好了

赞

叠搭宝箱 11 个月前

你好, 上面的那个表格为何说 FM不需要人工特征呢~~？最原始的那个FM 实际应该是需要的吧， 只是模型能算出来这些人工特征的两两组合特征

赞

湖心小笨酸 9 个月前

为什么我的图片有部分是模糊的，看不了

赞

精密度 7 个月前

赞，学习了。

赞

王王 1 个月前

请问，NFM增加的一个术语“Bi-interaction”，只是一个对FM second order项的一个定义性术语吧，与之没有什么不同吧？

赞